REPUBLIQUE TUNISIENNE

MINISTERE DE L'ENSEIGNEMENT SUPERIEUR ET DE LA RECHERCHE SCIENTIFIQUE

UNIVERSITE TUNIS EL MANAR

FACULTE DES SCIENCES DE TUNIS
DEPARTEMENT DES SCIENCES DE L'INFORMATIQUE

PROJET

Mise en place d'un Entrepôt de Données et Création de Dashboard avec Power BI

Thème : Formule 1

Réalisé par :

BEN SALAH Chahine *JAOUADI Yassine*

AFI Elaa *MASTOURI Mohamed Ali*

Encadrante : *MENSI Rihab*

Année Universitaire 2025-2026

Contents

Introduction 2
Chapitre 1 Choix du Thème et Justification 4
Richesse des données 4
Hétérogénéité des sources 4
Pertinence analytique 4
Chapitre 2 Collecte des Données 5
2.1 Source 1: Fichiers CSV (Kaggle) 5
2.2 Source 2: Fichier Excel 5
2.3 Source 3: API JSON Jolpica 5
Chapitre 3 Processus ETL avec SSIS 6
3.1 Architecture des packages SSIS 6
3.2 Package 1: Load_CSV_Sources.dtsx 6
3.3 Package 2: Load_Excel_Standings.dtsx 7
3.4 Package 3: Load_API_Jolpica.dtsx 7
3.5 Package 4: Master.dtsx 8
Chapitre 4 Architecture de l'entrepôt de données 8
4.1 Modèle en étoile 9
4.2 Description des tables 9
4.3 Validation des données chargées 9
Chapitre 5 Dashboards Power BI 12
5.1 Connexion à DW_F1 12
5.2 Modèle relationnel Power BI 12
5.3 Mesures DAX 13
5.4 Dashboard 1: Driver Performance 13
5.5 Dashboard 2: Constructor Battle 13
5.6 Dashboard 3 : Circuit Analysis 14
5.7 Dashboard 4 : Season Overview 15
Conclusion 16

Introduction

Ce rapport présente le projet de mise en place d'un entrepôt de données (Data Warehouse) et de création de Dashboard interactifs avec Power BI, réalisé dans le cadre du cours d'entrepôt de données.

Le domaine choisi est celui de la Formule 1, sport mécanique mondialement connu et riche en données historiques. L'objectif de ce projet est de centraliser des données provenant de sources hétérogènes dans un entrepôt de données structuré, de les transformer via un processus ETL développé avec SSIS (SQL Server Integration Services), et de les visualiser sous forme de Dashboards interactifs dans Power BI.

Le projet couvre l'ensemble de la chaine de traitement des données : collecte multi-sources, nettoyage et transformation, chargement dans SSMS (SQL Server Management Studio), et visualisation analytique via Power BI Desktop.

Chapitre 1 Choix du Thème et Justification

Le thème retenu pour ce projet est la Formule 1 (F1). Ce choix est motivé par plusieurs considérations.

Richesse des données

La Formule 1 dispose d'un historique de données couvrant plus de 70 ans de compétitions (depuis 1950), avec des informations détaillées sur les pilotes, les écuries, les circuits, les courses et les résultats. Ces données présentent une complexité et une richesse suffisantes pour justifier la mise en place d'un entrepôt de données complet.

Hétérogénéité des sources

Les données F1 sont disponibles sous plusieurs formats complémentaires : fichiers CSV historiques sur Kaggle, API REST au format JSON via la plateforme Jolpica (successeur de l'API Ergast), et fichiers Excel de synthèse.

Pertinence analytique

Le domaine de la Formule 1 permet de répondre à de nombreuses questions d'analyse métier : évolution des performances des pilotes dans le temps, dominance des écuries par saison, analyse géographique des circuits, comparaison des champions. Ces questions alimentent directement les Dashboards Power BI.

Domaine choisi : Sport mécanique Formule 1 (F1) Période couverte : 1950 à 2024 (plus de 70 ans de données) Nombre de sources : 3 sources hétérogènes (CSV, Excel, API JSON)

Chapitre 2 Collecte des Données

Conformément aux exigences du projet, trois sources de données hétérogènes ont été combinées pour alimenter l'entrepôt de données DW_F1.

N	Type	Origine	Contenu
Source 1	Fichiers CSV (5 fichiers)	Kaggle Ergast F1 Dataset	861 pilotes, 1125 courses, 26 759 résultats depuis 1950
Source 2	Fichier Excel (.xlsx)	Cree manuellement (F1_Season_Standings)	16 saisons 2009-2024, classements drivers & constructors
Source 3	API JSON REST	Jolpica API (api.jolpi.ca/ergast)	Classements 2023 : 22 pilotes avec points et victoires

Tableau 1: Description des trois sources de données

2.1 Source 1: Fichiers CSV (Kaggle)

Cinq fichiers CSV ont été téléchargés depuis la plateforme Kaggle (Ergast Motor Racing Dataset). Ces fichiers constituent la source principale du projet :

- circuits.csv 77 circuits avec coordonnées GPS (lat, lng), pays et altitude
- constructors.csv 212 écuries avec nationalité
- drivers.csv 861 pilotes avec date de naissance, nationalité et code trigramme
- races.csv 1 125 courses avec dates des sessions (FP1, FP2, FP3, qualification, sprint)
- results.csv 26 759 résultats de courses avec points, position, temps au tour le plus rapide

Ces fichiers utilisent la convention MySQL pour les valeurs nulles (la chaine \N), ce qui a nécessité un traitement spécifique lors de la phase ETL dans SSIS.

2.2 Source 2: Fichier Excel

Un fichier Excel F1_Season_Standings.xlsx a été créé avec les données de classement par saison de 2009 à 2024. Ce fichier contient trois feuilles complémentaires :

- Driver_Championships 16 lignes : champion pilote, nationalité, écurie, victoires, podiums, pôles et points par saison
- Constructor_Championships 16 lignes : écurie championne, ses deux pilotes et le total des points
- Season_Summary 16 lignes : nombre de courses, pilotes, écuries et nouveau circuit de la saison

2.3 Source 3: API JSON Jolpica

L'API Jolpica (https://api.jolpi.ca/ergast/f1/) est le successeur officiel de la défunte API Ergast. Elle fournit les données F1 au format JSON via des requêtes HTTP REST sans nécessiter d'authentification. Pour ce projet, les classements pilotes 2023 ont été récupérés via l'Endpoint :

```
GET https://api.jolpi.ca/ergast/f1/2023/driverStandings.json
```

La réponse JSON a été traitée et transformée en fichier CSV intermédiaire (api_standings.csv) via un Script Task C# dans SSIS, puis charge dans la table de staging STG_API_Standings.

Chapitre 3 Processus ETL avec SSIS

Le processus ETL (Extract, Transform, Load) a été développé avec SQL Server Integration Services (SSIS) dans Visual Studio 2022. Il est organisé en quatre packages complémentaires.

3.1 Architecture des packages SSIS

Package SSIS	Rôle	Description
`Load_CSV_Sources.dtsx`	*Package 1*	Charge les 5 fichiers CSV (circuits, constructors, drivers, races, results) dans le DW
`Load_Excel_Standings.dtsx`	*Package 2*	Charge le fichier Excel F1_Season_Standings.xlsx dans DIM_Season_Standings
`Load_API_Jolpica.dtsx`	*Package 3*	Charge le fichier CSV généré depuis l'API Jolpica dans STG_API_Standings
`Master.dtsx`	*Package 4 (Orchestrateur)*	Appelle les 3 packages precedents en sequence via Execute Package Task

Tableau 2 : Description des quatre packages SSIS

Chaque package est autonome et peut être exécuté indépendamment. Le package Master.dtsx orchestre l'exécution séquentielle de l'ensemble du pipeline ETL.

3.2 Package 1: Load_CSV_Sources.dtsx

Ce package charge les cinq fichiers CSV dans les tables de dimension et de fait de l'entrepôt de données. Il est organisé en cinq Data Flow Tasks exécutés en sequence, relies par des contraintes de précédence pour garantir que les dimensions sont chargées avant la table de faits.

Les transformations appliquées incluent :

- Conversion des types de données : les colonnes numériques (IDs, années, etc.) sont converties de DT_STR en DT_I4 ou DT_R8 dans l'onglet Advanced de chaque Flat File Source
- Gestion des valeurs nulles : les chaines \N sont remplacées par de vrais NULL via des transformations Derived Column (expression : [col] == "\\N" ? NULL(DT_WSTR,n) : (DT_WSTR,n)[col])
- Uniformisation Unicode : toutes les colonnes de type chaine sont converties en DT_WSTR (Unicode) pour assurer la compatibilité avec les colonnes NVARCHAR de SQL Server

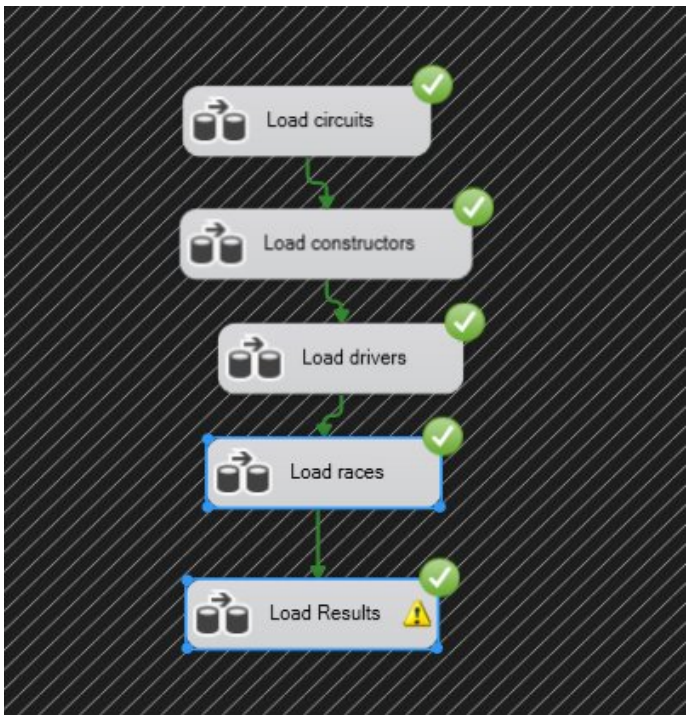

Figure 1: Control Flow du package Load_CSV_Sources.dtsx (5 taches vertes)

3.3 Package 2: Load_Excel_Standings.dtsx

Ce package charge le fichier Excel F1_Season_Standings.xlsx dans la table DIM_Season_Standings. Il utilise un Excel Source connecte à la feuille Driver_Championships$ et un OLE DB Destination cible vers DW_F1.

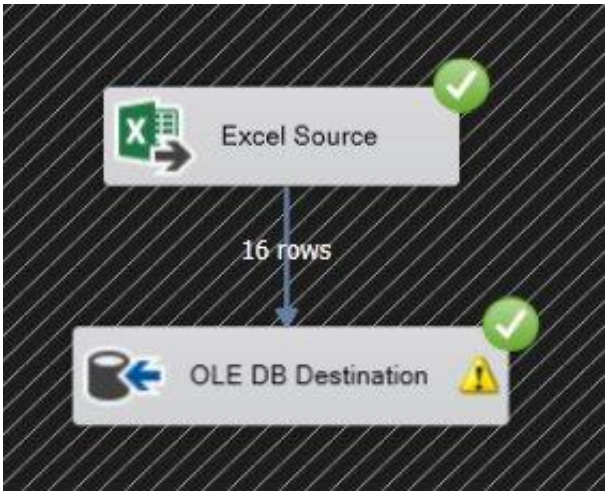

Figure 2: Data Flow du package Load_Excel_Standings.dtsx (16 lignes chargées)

3.4 Package 3: Load_API_Jolpica.dtsx

Ce package charge le fichier api_standings.csv généré depuis l'API Jolpica dans la table STG_API_Standings. Le fichier CSV a été pré-généré à partir de la réponse JSON de l'API et contient les classements de 22 pilotes pour la saison 2023 (position, points, victoires, code pilote).

Figure 3 : Control Flow du package Load_API_Jolpica.dtsx (22 lignes chargées)

3.5 Package 4: Master.dtsx

Le package Master.dtsx orchestre l'exécution séquentielle des trois packages precedents via trois composants Execute Package Task relies en sequence. Il garantit l'ordre correct de chargement : d'abord les dimensions (CSV et Excel), puis les données de staging (API).

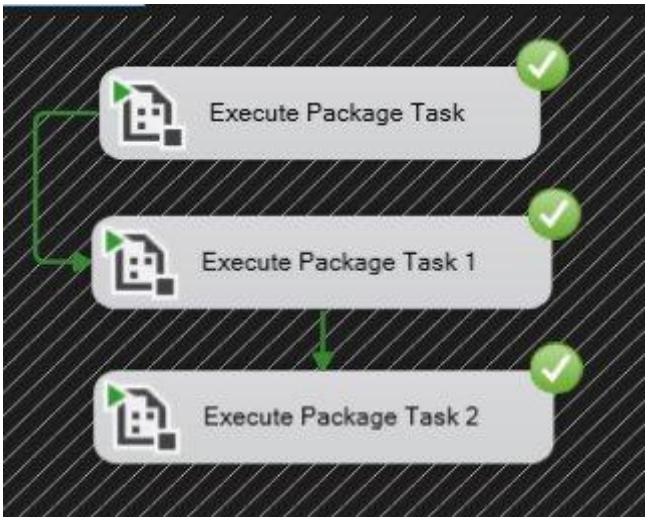

Figure 4: Control Flow du package Master.dtsx 3 (Execute Package Tasks verts)

Chapitre 4 Architecture de l'entrepôt de données

4.1 Modèle en étoile

L'entrepôt de données DW_F1 adopte un schéma en étoile (star schéma). La table de faits FACT_Results est au centre, entourée de quatre tables de dimension. Ce modèle a été choisi pour sa simplicité de compréhension, ses performances en lecture et sa compatibilité optimale avec Power BI.

Tables de Dimension	Table de Faits
• DIM_Circuits (77 lignes) • DIM_Constructors (212 lignes) • DIM_Drivers (861 lignes) • DIM_Races (1125 lignes) • DIM_Season_Standings (16 lignes)	• FACT_Results (26 759 lignes) • Clés étrangères : raceId, driverId, constructorId • Mesures : points, position, laps, milliseconds, fastestLapSpeed • Statut : statusId (DNF, NC, etc.)

4.2 Description des tables

Les tables de l'entrepôt de données DW_F1 sont organisées comme suit. Les types de données ont été alignes sur NVARCHAR pour les colonnes textuelles afin d'assurer la compatibilité Unicode avec SSIS.

DIM_Circuits	circuitId (PK), circuitRef, name, location, country, lat, lng, alt, url
DIM_Constructors	constructorId (PK), constructorRef, name, nationality, url
DIM_Drivers	driverId (PK), driverRef, number, code, forename, surname, dob, nationality, url
DIM_Races	raceId (PK), year, round, circuitId (FK), name, date, time, fp1_date, fp2_date, fp3_date, quali_date, sprint_date
DIM_Season_Standings	Season (PK), Champion_Driver, Nationality, Constructor, Wins, Podiums, Poles, Points, Races_Entered
FACT_Results	resultId (PK), raceId (FK), driverId (FK), constructorId (FK), number, grid, position, positionText, positionOrder, points, laps, time, milliseconds, fastestLap, rank, fastestLapTime, fastestLapSpeed, statusId

4.3 Validation des données chargées

Après exécution du pipeline ETL complet, une requête de validation a été exécutée dans SSMS pour confirmer le chargement correct des données dans toutes les tables.

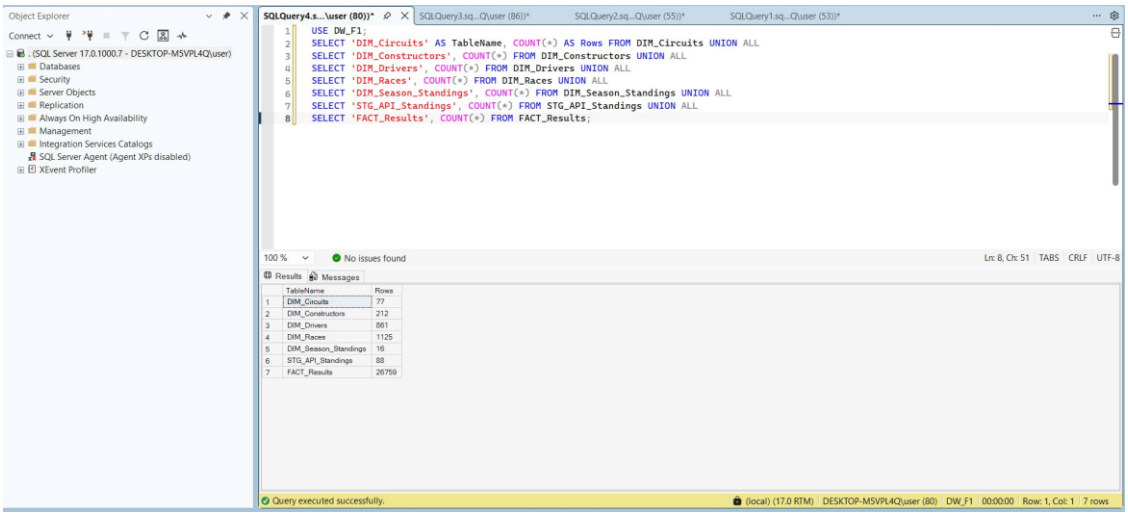

Figure 5: Résultats de la requête de validation dans SSMS 7 tables chargées avec succès

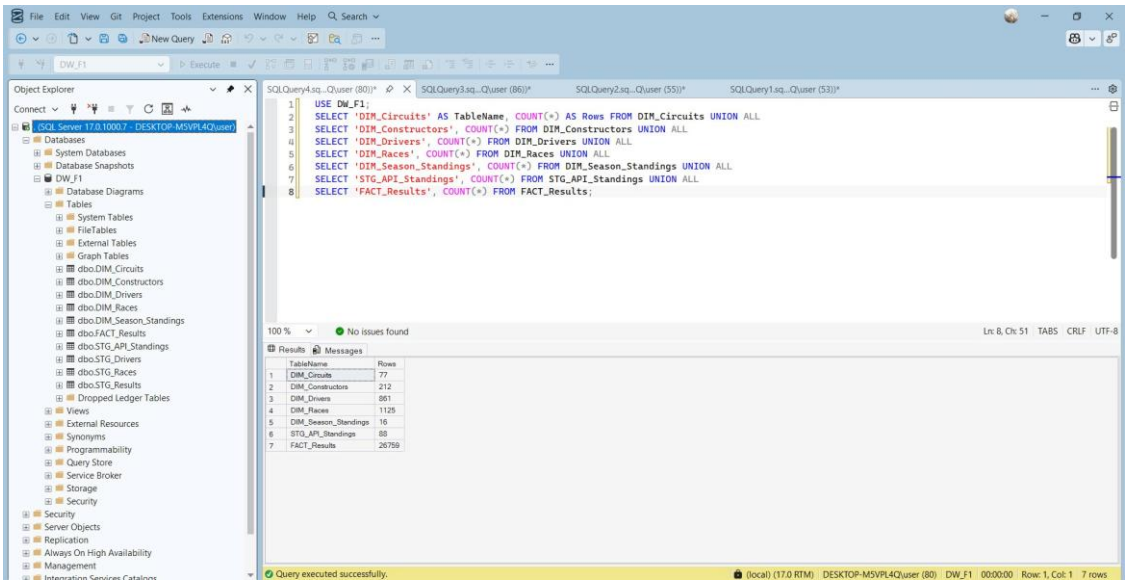

Figure 6: Structure de l'entrepôt de données DW_F1 dans l'Object Explorer de SSMS

Table	Lignes	Description
DIM_Circuits	77	Circuits du monde entier
DIM_Constructors	212	Écuries F1
DIM_Drivers	861	Pilotes F1
DIM_Races	1 125	Courses depuis 1950
DIM_Season_Standings	16	Saisons 2009-2024
STG_API_Standings	88	Classements API Jolpica
FACT_Results	26 759	Résultats de courses

Tableau 3: Statistiques de chargement des tables du DW_F1

Chapitre 5 Dashboards Power BI

Power BI Desktop a été connecte directement à l'entrepôt de données DW_F1 via une connexion SQL Server (mode Import). Quatre pages de Dashboards interactifs ont été créées pour répondre aux principales questions d'analyse métier du domaine F1.

5.1 Connexion à DW_F1

La connexion a été établie via : Accueil > Obtenir les données > SQL Server. Les paramètres utilises sont :

- Serveur : localhost
- Base de données : DW_F1
- Mode de connectivite : Import
- Tables sélectionnées : DIM_Circuits, DIM_Constructors, DIM_Drivers, DIM_Races, DIM_Season_Standings, FACT_Results

5.2 Modèle relationnel Power BI

Power BI a détecté automatiquement les relations entre les tables basées sur les clés étrangères. La relation entre DIM_Season_Standings et DIM_Races a été créée manuellement (Season -> year) dans la vue Modèle.

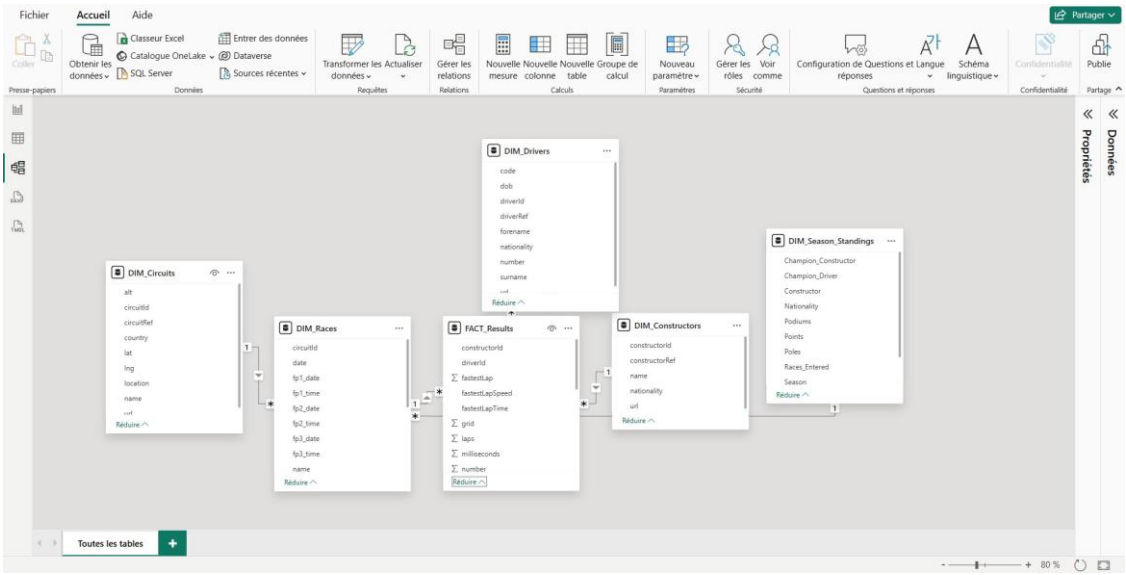

Figure 7 : Vue Modèle Power BI Schema en étoile avec 5 relation

5.3 Mesures DAX

Cinq mesures DAX ont été créées dans la table FACT_Results pour alimenter les visuels des Dashboards:

TotalPoints	`SUM(FACT_Results[points])`
TotalWins	`CALCULATE(COUNTROWS(FACT_Results), FACT_Results[position] = 1)`
Podiums	`CALCULATE(COUNTROWS(FACT_Results), FACT_Results[position] <= 3)`
WinRate	`DIVIDE([TotalWins], COUNTROWS(FACT_Results), 0)`
AvgPointsPerRace	`DIVIDE([TotalPoints], COUNTROWS(FACT_Results), 0)`

Tableau 4 : Mesures DAX créées dans FACT_Results

5.4 Dashboard 1: Driver Performance

Ce Dashboard analyse les performances individuelles des pilotes F1 depuis 1950. Il comprend un graphique a barres horizontales montrant les 10 pilotes avec le plus de points en carrière, une carte affichant le nombre total de victoires (1 128), une carte affichant le nombre de podiums (14 000) et un segment de filtrage par année.

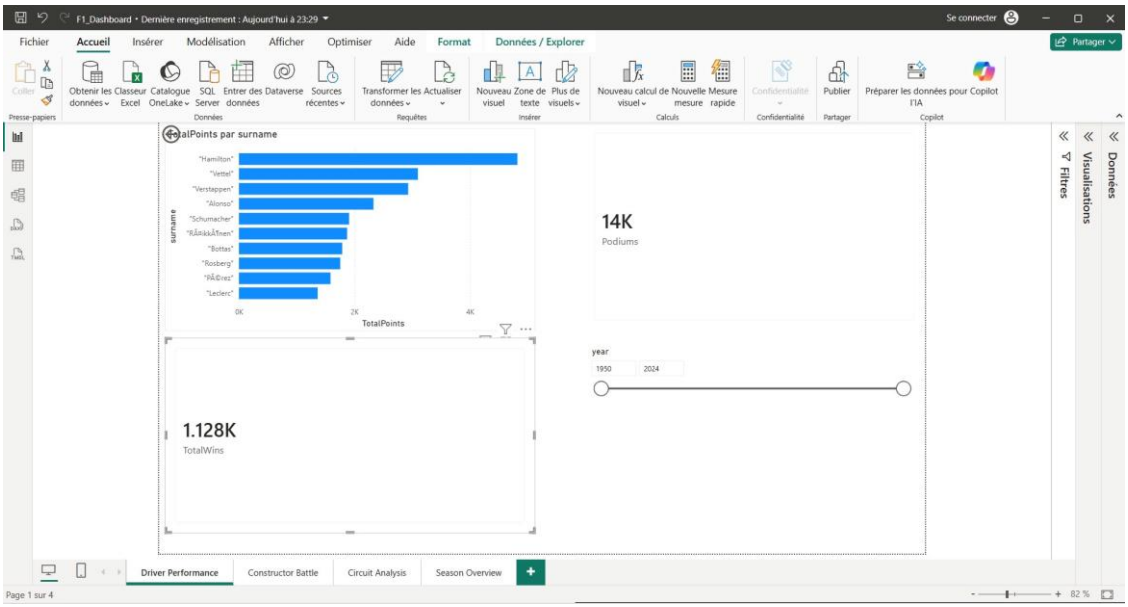

Figure 8: Dashboard 1 Driver Performance (Hamilton en tête avec ~4 500 points en carrière)

5.5 Dashboard 2: Constructor Battle

Ce Dashboard analyse la domination des écuries F1 dans le temps. Il comprend un graphique a barres horizontales des écuries par points totaux (Ferrari en tête), un graphique en secteurs (camembert) montrant la répartition des victoires par écurie (249 victoires pour Ferrari, 185 pour McLaren) et un segment de filtrage par année.

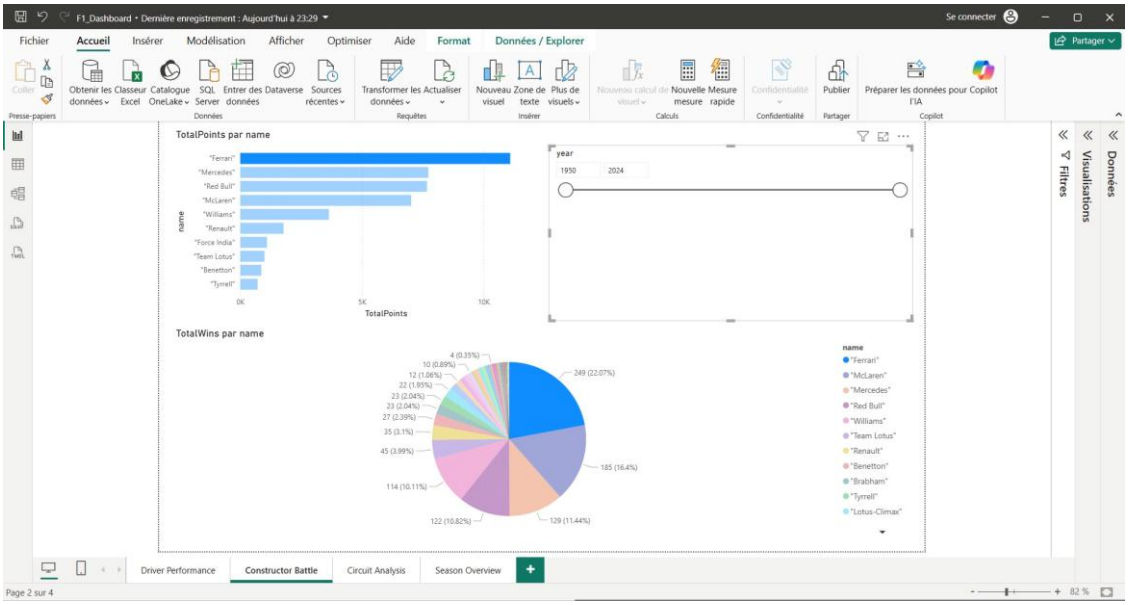

Figure 9: Dashboard 2 Constructor Battle (Ferrari domine avec 249 victoires tous temps)

5.6 Dashboard 3 : Circuit Analysis

Ce Dashboard présente une analyse géographique des circuits F1. Il comprend une carte mondiale Bing avec des bulles positionnées selon les coordonnées GPS (lat, lng) de chaque circuit, un histogramme des circuits par points totaux engrangés et un segment de filtrage par pays. On observe une forte concentration de circuits en Europe.

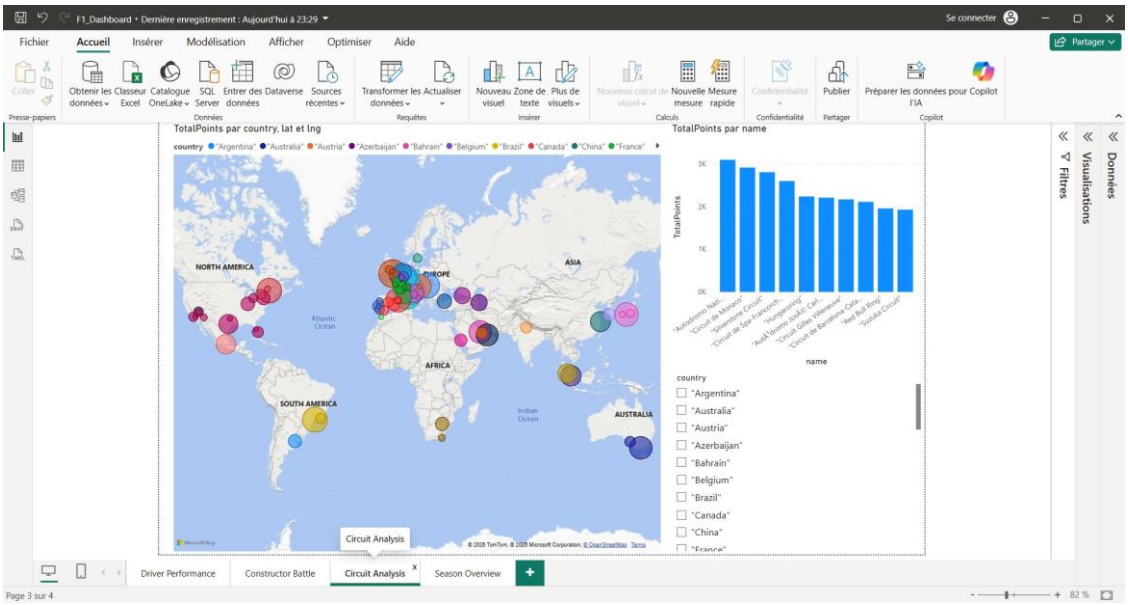

Figure 10: Dashboard 3 Circuit Analysis (carte mondiale des 77 circuits F1)

5.7 Dashboard 4 : Season Overview

Ce Dashboard présente une vue synthétique de l'évolution de la F1 par saison. Il comprend un graphique en courbes montrant l'évolution des points totaux par année (forte augmentation à partir de 2010 due au changement du barème), un histogramme des victoires par saison provenant de DIM_Season_Standings, une carte affichant la moyenne de points par course (1,99) et un segment de filtrage par champion.

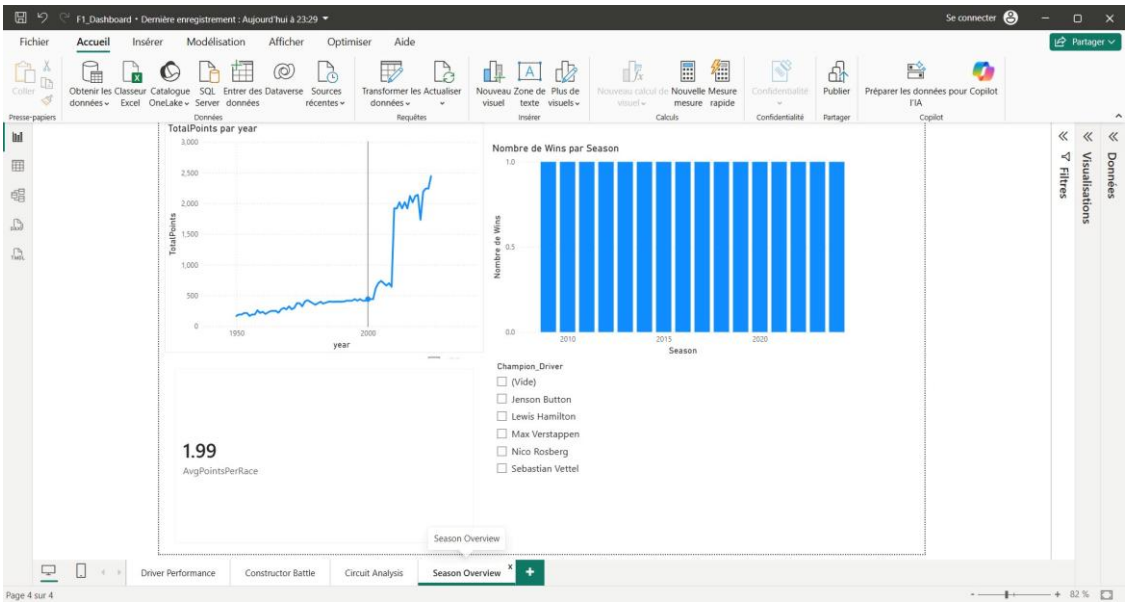

Figure 11: Dashboard 4 Season Overview (Jenson Button, Lewis Hamilton, Max Verstappen, Nico Rosberg, Sebastian Vettel)

Conclusion

Ce projet a permis de mettre en œuvre une solution complète d'entrepôt de données et de business intelligence appliquée au domaine de la Formule 1.

Les principaux résultats obtenus sont les suivants :

✓	3 sources de données hétérogènes intégrées (CSV, Excel, API JSON)
✓	4 packages SSIS développes avec gestion des valeurs nulles (\N) et conversion Unicode
✓	Entrepôt de données DW_F1 en schéma en étoile avec 26 759 faits et 5 dimensions
✓	Ordonnancement automatique via SQL Server Agent
✓	4 Dashboards Power BI interactifs couvrant pilotes, écuries, circuits et saisons
✓	5 mesures DAX pour l'analyse des performances

Sur le plan technique, les principaux défis rencontres ont concerné la gestion de la compatibilité Unicode entre SSIS et SQL Server (nécessite de convertir toutes les colonnes textuelles en NVARCHAR et les flux en DT_WSTR), la gestion des valeurs nulles encodées sous forme de chaine \N dans les fichiers CSV d'origine MySQL, et l'indisponibilité de l'API Ergast remplacée par Jolpica.